Sztuczna Inteligencja i Inżynieria Wiedzy

Opis projektu

„System do detekcji samochodów oraz rozpoznawania tablic rejestracyjnych”

Mateusz Pakuła
238336

1. Cel projektu

Celem projektu jest opracowanie systemu, w skład którego wchodzą funkcjonalności takie jak:
- detekcja samochodów i innych obiektów
- określanie stanów samochodu takich jak: odjazd i przyjazd z wyznaczonego miejsca parkingowego, ruch
- określanie stanu oświetlenia (włączone/wyłączone)
- wykrywanie tablicy rejestracyjnej, segmentacja symboli z tablicy rejestracyjnej i ich klasyfikacja

2. Opis działania systemu

System zaimplementowany został w języku Python z wykorzystaniem bibliotek OpenCV, PyTorch i NumPy. Działanie opiera się na: określeniu stanu oświetlenia, wykryciu obiektów, śledzeniu, klasyfikacji stanu samochodów, wykryciu tablicy rejestracyjnej, segmentacji i następnie klasyfikacji znaków z tablicy rejestracyjnej.

Określanie stanu oświetlenia

Do określania poziomu światła na obrazie została użyta funkcja, która oblicza średnią wartość piksela:

$$ps(img) = \frac{\sum_{y=0}^{h} \sum_{x=0}^{w} img[y][x]}{w * h}$$

gdzie:

img – obraz, przekonwertowany na skalę szarości (w projekcie użyto metody color z opencv)

w – szerokość obrazu w pikselach

h – długość obrazu w pikselach

Światło zostaje uznane za włączone, jeżeli wartość funkcji ps dla obrazu jest większa od poziomu ustalonego w programie (wartość domyślna w programie została arbitralnie ustawiona na 20)

Detekcja

Do wykrywania obiektów na obrazie wykorzystano rozwiązanie o nazwie Single Shot MultiBox Detector (https://arxiv.org/abs/1512.02325) , bazujące na konwolucyjnej sieci neuronowej MobileNetV1.

Dane uczące

Dane uczące, na których został wytrenowany model składają się z danych utworzonych na bazie dostarczonych materiałow wideo obrobionych w narzędziu Scalabel (https://www.scalabel.ai/), oraz zbioru Open Images (https://storage.googleapis.com/openimages/web/index.html). Do pobierania

danych ze zbioru Open Images przygotowany został skrypt **open_images_downloader.py**, które można wywołać poleceniem o składni:

python open_images_downloader.py --root ŚCIEŻKA **--class_names** ”nazwa1,nazwa2,...” **[--include_depiction] [--num_workers** L_WĄTKÓW**] [--retry** L_PRÓB**] [--filter_file** ”id1,id2,id3”**] [--remove_overlapped]**

gdzie:

--root – katalog główny, w którym przechowywany ma być zbiór danych
--class_names – nazwy klas, tj. samochód, które mają zostać pobrane
--include_depiction – mówi, że dane mają zawierać opis
--num_workers – liczba pracujących wątków
--retry – liczba prób podczas pobierania
--filter_file – identyfikatory plików, które mają zostać zignorowane
--remove_overlapped – mówi, że etykiety przesłonięte przez inne etykiety mają zostać usunięte

Uczenie modelu

Szczegóły dotyczące funkcji celu dostępne są w dokumentacji modelu Single Shot MultiBox Detector. Do optymalizacji funkcji celu wykorzystana została metoda stochastycznego spadku wzdłuż gradientu. Do trenowania modelu został przygotowany skrypt **train_ssd.py**, uruchamiany za pomocą polecenia o składni:

python train_ssd.py --train_datatype {bdd | open_images}
--validation_datatype {bdd | open_images} --datasets ”sciezka1 sciezka2 ...”
--validation_dataset SCIEŻKA **[--labels** ŚCIEŻKA**] [--freeze_base_net]**
[{--lr | --learning_rate} WARTOŚĆ**] [--momentum** WARTOŚĆ**] [--weight_decay** WARTOŚĆ**]**
[--gamma WARTOŚĆ**] [--base_net_lr** WARTOŚĆ**] [--extra_layers_lr** WARTOŚĆ**]**
[{--base_net ŚCIEŻKA **| --pretrained_net** ŚCIEŻKA **| --resume** ŚCIEŻKA**}]**
[--scheduler {multi-step [--milestones WARTOŚĆ**] | cosine [--t_max** WARTOŚĆ**]}]**
[--batch_size WARTOŚĆ**] [--num_epochs** WARTOŚĆ**] [--num_workers** WARTOŚĆ**]**
[--validation_epochs WARTOŚĆ**] [--debug_steps** WARTOŚĆ**] [--use_cuda {True | False}]**
[--checkpoint_folder ŚCIEŻKA**] [--balance_data]**

gdzie:

--train_datatype – typ zbioru danych uczących; musi być podany osobno dla każdej podanej ścieżki, np. mając 2 zbiory: jeden z narzędzia Scalabel, a drugi z Open Images należy napisać „--train_datatype bdd open_images”
--validation_datatype – typ zbioru walidacyjnego
--datasets – ścieżka lub ścieżki do zbiorów treningowych
--validation_dataset – ścieżka do zbioru walidacyjnego
--labels – ścieżka do pliku tekstowego z etykietami oddzielonymi przecinkiem, który mówi jaki numer powinien zostać przypisany danej etykiecie, np. mając etykiety „car”, „bike” i „person”, umieszczając w pliku „car,person,bike” etykieta „car” będzie miała nr 1, etykieta „person” nr 2, a etykieta „bike” nr 3

--freeze_baze_net – mówi o tym, że wagi bazowej sieci (MobileNetV1) nie powinny być zmieniane
--lr lub --learning_rate – początkowy współczynnik długości kolejnego kroku w gradiencie
--momentum – współczynnik pędu gradientu stochastycznego
--weight_decay – współczynnik regularyzacji L2 gradientu stochastycznego
--gamma – wspołczynnik gamma gradientu stochastycznego
--base_net_lr – współczynnik długości kroku dla sieci bazowej (MobileNetV1)
--extra_layers_lr – współczynnik długości kroku dla pozostałych warstw modelu
--base_net – ścieżka do sieci bazowej (sieć jest inizjalizowana przez metodę **init_from_base_net**)
--pretrained_net – ścieżka pretrenowanej sieci (inicjalizacja przez metodę **init_from_pretrained_ssd**)
--resume – ścieżka do trenowanej wcześniej sieci („zwykła” inicjalizacja przez metodę **load**)
--scheduler – wybór planisty do dynamicznego dostosowywania kroku w gradiencie
--milestones – parametr określający „kamienie milowe” w planiście MultiStepLR
--t_max – maksymalna liczba iteracji w planiście Cosine Annealing
--batch_size – rozmiar batcha
--num_epochs – liczba epok, które mają się wykonać

--num_workers – liczba wątków
--validation_epochs – określa liczbę epok, co które ma być dokonywana walidacja i zapis modelu
--debug_steps – liczba kroków, co które ma zostać wyświetlony log
--use_cuda – wartość logiczna wskazująca, czy używać GPU, czy nie
--checkpoint_folder – ścieżka do zapisu modelu
--balance data – użycie powoduje wyrównanie liczby etykiet każdej klasy

Śledzenie

Śledzenie samochodów jest procesem podzielonym na 3 etapy:

– pobranie wstępnego zbioru z detekcji obiektów

– utworzenie unikalnego identyfikatora dla każdego z samochodów

– monitorowanie każdego obiektu-samochodu podczas kolejnych klatek, zachowując przydzielone im unikalne identyfikatory

Pobranie wstępnego zbioru

Podczas pobrania początkowego zbioru wykrytych obiektów, obiekty oznaczone jako samochód są odseparowywane od pozostałych.

Utworzenie unikalnego ID

Każdy odseparowany samochód otrzymuje swój własny identyfikator.

Monitorowanie

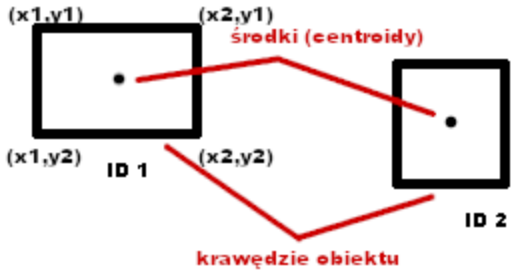

Rys. 1

Pierwszym krokiem jest obliczenie współrzędnych środka każdego z obiektów (samochodów) w układzie współrzędnych. Dla każdego prostokąta-ramki współrzedne wyliczane są ze wzorów:

$$x=\frac{x_1+x_2}{2} \qquad y=\frac{y_1+y_2}{2}$$

Kolejnym krokiem jest porównanie środków obiektów z poprzedniej iteracji do obiektów z nowej iteracji.

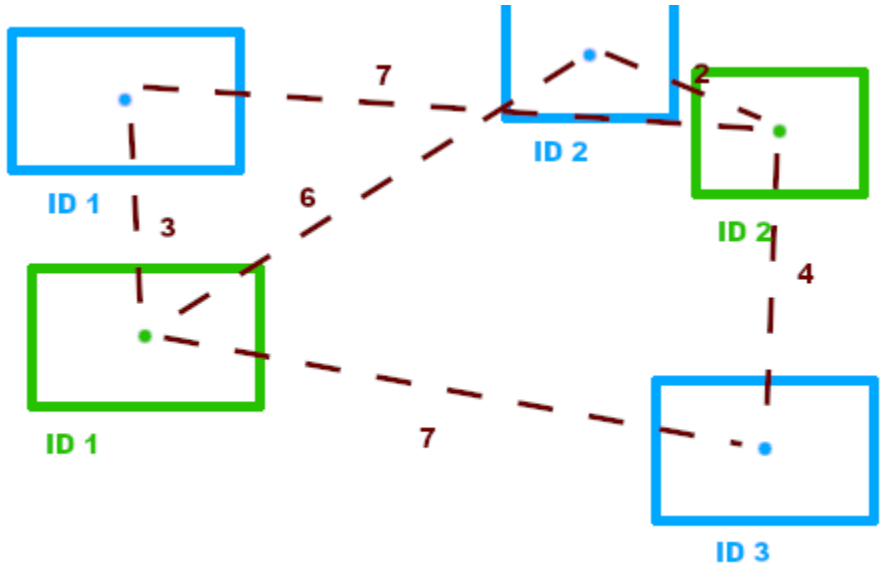

Rys. 2 – Odległości pomiędzy środkami prostokątów

Dla każdego środka prostokąta z nowej iteracji (kolor niebieski) liczona jest odległość do każdego środka prostokąta z nowej iteracji (kolor zielony) zgodnie ze wzorem:

$l(a,b)=|b_x-a_x|+|b_y-a_y|$ (a, b – środki prostokątów, będące punktami w układzie współrzędnych)

Następnie każdemu obiektowi z nowej iteracji przyznawany jest identyfikator tego prostokąta, którego środek był najbliżej środka nowego prostokąta. W rysunku drugim – niebieski prostokąt w lewym górnym rogu jest najbliżej prostokąta o ID 1, dlatego też zostaje mu przyznany jego identyfikator. W przypadku większej liczby nowych obiektów-samochodów, niż w poprzedniej iteracji, przyznawany jest nowy identyfikator.

Określanie stanu samochodów

W systemie istnieją 4 stany opisujące samochód: domyślny – bez nazwy, w ruchu – MOVE, samochód zaparkował w pewnym miejscu parkingowym – ARRIVED, samochód wyjeżdża z ww. miejsca parkingowego – LEFT. Etykieta MOVE przyznawana jest samochodowi, którego środek przesunął się w jednej iteracji o 5 jednostek według wzoru na odległość między punktami stosowanego przy śledzeniu obiektów. Etykieta ARRIVED przyznawana jest wtedy, gdy prostokąt otaczający samochód i prostokąt, którym oznaczone jest miejsce parkingowe mają część wspólną. Etykieta LEFT przypisywana jest na określoną liczbę iteracji samochodowi, który poprzednio posiadał etykietę ARRIVED, a jego prostokąt-ramka i prostokąt oznaczający miejsce parkingowe nie nachodzą już na siebie.

Wykrywanie tablicy rejestracyjnej

Pierwszym krokiem do odnalezienia fragmentu obrazu z tablicą rejestracyjną jest utworzenie binarnego obrazu na bazie obrazu (w skali szarości) z wykrytym przez SSD samochodem. Stosowane do tego jest progowanie adaptacyjne, gdzie obraz dzielony jest na obszary, potem w każdym obszarze obliczana jest średnia wartość intensywności i dla każdego obszaru dzielony jest osobny próg. (W projekcie wykorzystana została metoda adaptiveThreshold z opencv).

Rys. 3 - Samochód w skali szarości

Rys. 4 - Samochód po zastosowaniu progowania binarnego

Kolejnym krokiem jest utworzenie zbioru regionów z połączonymi pikselami (w projekcie wykorzystano metode measure.labels z pakietu skimage). Piksele nazywane są połączonymi wtedy, gdy są sąsiadujące oraz mają takie same wartości i wyselekcjonowaniem tych, które spełniają określone warunki: wysokość zawiera się w ustalonym przedziale; szerokość zawiera się w ustalonym przedziale; szerokość obrazu jest co najmniej trzy razy mniejsza niż wysokość; obszar w całości znajduje się w dolnej połowie obrazu. Następnie dla każdego obszaru, który spełnia kryteria dokonywane jest rzutowanie perspektywiczne, aby zredukować jego zniekształcenia.

Segmentacja znaków tablicy rejestracyjnej

Początkową operacją przeprowadzoną na obrazie z tablicą rejestracyjną jest przekonwertowanie go do skali szarości, a następnie zastosowanie rozmycia Gaussa z kernelem o rozmiarach 1x1. Kolejnym krokiem jest poddanie obrazu progowaniu binarnemu przy wykorzystaniu metody Otsu.

Rys. 5 – Obraz tablicy rejestracyjnej przed przetworzeniem

Rys. 6 – Obraz po przeprowadzeniu progowania

Po przeprowadzeniu binaryzacji, obraz dzielony jest w pionie na 8 równych segmentów. Każdy kolejny segment przesuwany jest w prawo do momentu, w którym wszystkie wartości pikseli z środkowych 20% prawej krawędzi, będą wynosić 1 (będą białe).

Rys. 7 – Segmenty nałożone na obraz tablicy rejestracyjnej

W dalszej kolejności, dla każdego segmentu, analogicznie do wykrywania tablicy rejestracyjnej, tworzony jest zbiór regionów z połączonymi pikselami, które spełniają określone kryteria: wysokość i szerokość zawierają się w określonych przedziałach. Jako nowe wymiary segementu ustawiane są wymiary regionu, który posiada największe pole w jego obrębie.

Rys. 8 – Segmenty po korekcie wymiarów

Finalnie, każdy segment podawany jest na wejście sieci neuronowej klasyfikującej znaki.

Klasyfikacja znaków

Do rozpoznawania znaków została wykorzystana konwolucyjna sieć neuronowa o strukturze:

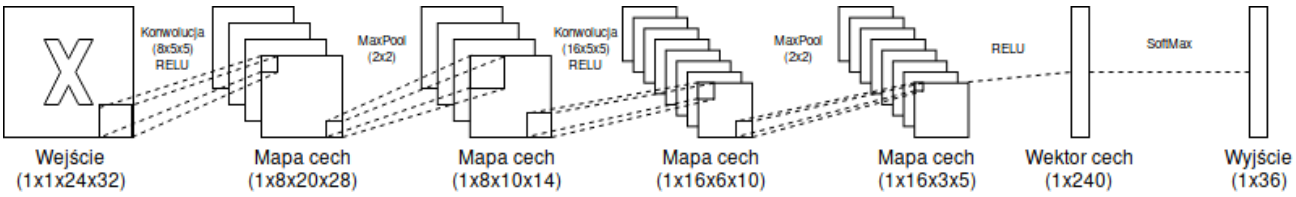

Rys. 9 – Schemat architektury konwolucyjnej sieci neuronowej.

Gdzie przesunięcie przy operacjach konwolucji jest równe 1, a MaxPool 2. Dwa pierwsze wymiary wejścia (1x1) związane są z faktem, że kolory obrazu są w skali szarości zamiast w formacie RGB, a sam obraz posiada tylko jedną warstwę.

Dane uczące

Do uczenia modelu wykorzystany został plik graficzny, wewnątrz którego zebrane są wszystkie znaki występujące na tablicach rejestracyjnych oraz plik tekstowy mapujący nazwę klasy do . Zostały one podzielone na osobne obrazy o wymiarach 24x32. Dodatkowo cały zbiór został uzupełniony o 10000 kopii obrazów dla każdej klasy, na które zostały zaaplikowane metody data augmentation: skalowanie od 30% do 140%, obrót od -20 do 20 stopni, odwrócenie kolorów obrazu, dropout do 40% pikseli, rozmycie gaussa.

Uczenie modelu

Do optymalizacji funkcji celu wykorzystana została metoda stochastycznego spadku wzdłuż gradientu. Do trenowania modelu został przygotowany skrypt **train_cnn.py**, uruchamiany za pomocą polecenia o składni:

python train_cnn.py [--use_cuda {True | False}] [--dataset ŚCIEŻKA**] [--batch_size** WARTOŚĆ**]**
[--learning_rate WARTOSĆ**] [--num_epochs** WARTOŚĆ**] [--store_path** ŚCIEŻKA**]**
[--model ŚCIEŻKA**] [--imgaug {True [--mult** WARTOŚĆ**] | False}]**

gdzie:

--use_cuda – parametr mówiący o tym, czy podczas uczenia ma być wykorzystywany GPU
--dataset – ścieżka do folderu, w którym znajduje się plik charset.png i labels.txt
--batch_size – rozmiar batcha
--learning_rate – współczynnik długości kroku w gradiencie
--num_epochs – liczba epok, przez które będzie trenowany model
--store_path – ścieżka do katalogu, w którym zapisany zostanie model po wyuczeniu
--model – ścieżka do modelu, który ma być trenowany

--imgaug – parametr mówiący o tym, czy dane mają zostać poddane procesowi Data Augmentation
--mult – wartość mówiąca o tym, ile razy zbiór danych ma zostać zwielokrotniony przed procesem Data Augmentation